

Universidad del Valle de Guatemala

Facultad de Ingeniería

Departamento de Computación

Data Science

1966

UNIVERSIDAD

GUATEMALA

LABORATORIO V

CLASIFICACIÓN DE TWEETS
USANDO MINERÍA DE TEXTO

DEL VALLE DE

Estuardo André Castro Bonifaz – 23890

Juan Marcos Cruz Melara – 23110

André Emilio Pivaral López – 23574

Excelencia que trasciende

Catedrático: Boris Fernando Becerra Peláez

Sección: 30

Nueva Guatemala de la Asunción, 30 de agosto de 2026

Índice

1. Resumen	1
2. Introducción	1
3. Limpieza y preprocesamiento del texto	2
4. Frecuencia de palabras y n-gramas por categoría	3
5. Análisis exploratorio	3
6. Modelos de clasificación	4
7. Función de clasificación de tweets	6
8. Análisis de sentimiento	6
9. Tweets más positivos y más negativos por categoría	7
10.Variable de negatividad	8
11.Conclusiones	9

1. Resumen

Este informe documenta la clasificación de tweets del conjunto Natural Language Processing with Disaster Tweets de Kaggle, cuyo objetivo es determinar si un mensaje se refiere a un desastre real o no. Se trabajó con el archivo `train.csv`, que contiene 7,613 tweets etiquetados. El texto se limpió y se representó mediante unigramas y bigramas ponderados por frecuencia inversa de documento, y sobre esa representación se entrenaron y compararon tres modelos de clasificación. El mejor resultado se obtuvo con una regresión logística, con una exactitud de 0.83 y una medida F1 de 0.78 sobre el conjunto de prueba. Además se realizó un análisis de sentimiento con VADER que mostró que los tweets de desastre son en promedio más negativos que el resto, y se construyó una variable de negatividad cuya incorporación al modelo no mejoró la clasificación. El trabajo se completó con una función que clasifica un tweet nuevo sin preprocesar.

2. Introducción

La detección automática de mensajes sobre desastres en redes sociales es útil para el monitoreo de emergencias, ya que permite filtrar grandes volúmenes de texto y priorizar la información relevante. El conjunto de datos utilizado proviene de la competencia Natural Language Processing with Disaster Tweets de Kaggle y contiene el texto de cada tweet junto con las columnas de palabra clave, ubicación y una etiqueta binaria que indica si el tweet se refiere a un desastre real. El conjunto está formado por 7,613 registros, de los cuales el 57.0 por ciento corresponde a la clase de no desastre y el 43.0 por ciento a la clase de desastre, un desbalance moderado que se muestra en la Figura 1. El objetivo del laboratorio es construir un clasificador capaz de distinguir ambas categorías y analizar el lenguaje y el sentimiento asociado a cada una.




Figura 1: Balance de clases del conjunto de datos.

3. Limpieza y preprocesamiento del texto

El texto de los tweets se normalizó con una función de limpieza aplicada sobre la columna de texto. Las tareas realizadas fueron la conversión a minúsculas, la eliminación de direcciones url, la eliminación de las menciones de usuario y del símbolo de las etiquetas conservando la palabra que las acompaña, la decodificación de algunas entidades html frecuentes, la conservación del número 911 mediante una palabra marcador antes de eliminar el resto de los dígitos, la eliminación de la puntuación y los caracteres especiales, y la eliminación de las palabras vacías del idioma inglés y de las palabras de una sola letra. Las palabras vacías se obtuvieron del paquete NLTK.

Se conservó una copia del texto original sin modificar. La razón es que el análisis de sentimiento posterior utiliza una herramienta que aprovecha los emoticones, las mayúsculas y los signos de exclamación, elementos que se pierden en la versión limpia. De este modo la versión normalizada se usa para el cálculo de frecuencias y para los modelos, mientras que la versión original se reserva para el sentimiento.

4. Frecuencia de palabras y n-gramas por categoría

Se calcularon las palabras más frecuentes en cada categoría. En los tweets de desastre predominan términos de emergencia como fire, disaster, suicide, police, killed, storm y crash, mientras que en los tweets de no desastre dominan palabras de uso cotidiano. Este contraste indica que el vocabulario es en sí mismo un buen predictor de la clase.

Se calcularon también los bigramas y trigramas más frecuentes de la categoría de desastre. Los bigramas más frecuentes fueron expresiones con contexto claro, como suicide bomber, northern california, oil spill, burning buildings y california wildfire. Estas combinaciones aportan información que una sola palabra no captura, por lo que se decidió incorporar unigramas y bigramas en la representación de los modelos de clasificación.

5. Análisis exploratorio

El análisis exploratorio confirmó y amplió los hallazgos del apartado anterior. La palabra más repetida en cada categoría reflejó el contraste entre el vocabulario de emergencia y el cotidiano. Las nubes de palabras de la Figura 2 resumen visualmente ese contraste, con términos de catástrofe concentrados en la categoría de desastre. El histograma de la Figura 3 muestra las palabras más frecuentes en todo el conjunto, entre ellas varias de alta frecuencia general que aparecen en ambas categorías y que, por tanto, aportan poca capacidad discriminante; su peso se reduce automáticamente al usar la ponderación por frecuencia inversa de documento en los modelos.



Figura 2: Nubes de palabras de la categoría de desastre y de la categoría de no desastre.




Figura 3: Palabras más frecuentes en todo el conjunto.

La distribución de la longitud de los tweets por clase, en la Figura 4, es similar entre ambas categorías, por lo que la longitud por sí sola no separa las clases y no se utilizó como predictor.




Figura 4: Distribución de la longitud de los tweets por clase.

6. Modelos de clasificación

El texto normalizado se transformó en una matriz de características con unigramas y bigramas ponderados por frecuencia inversa de documento. El contexto se abordó precisamente a través de los bigramas, que capturan pares de palabras con significado propio. El conjunto se dividió en un ochenta por ciento para entrenamiento y un veinte por ciento para prueba, de forma estratificada para preservar la proporción de clases. Sobre esa representación se entrenaron tres algoritmos, una regresión logística, un Naive Bayes multinomial y una máquina de vectores de soporte lineal.

El Cuadro 1 presenta la exactitud y la medida F1 de cada uno sobre el conjunto de prueba.

Cuadro 1: Desempeño de los modelos de clasificación sobre el conjunto de prueba.

Modelo	Exactitud	F1
Regresión logística	0.8273	0.7821
Naive Bayes multinomial	0.8253	0.7719
Máquina de vectores de soporte lineal	0.8024	0.7672

La medida F1 se usó como criterio de selección porque las clases no están balanceadas y esta medida penaliza tanto los falsos positivos como los falsos negativos. El mejor modelo fue la regresión logística. El Cuadro 2 detalla su precisión, sensibilidad y F1 por clase, y la Figura 5 muestra su matriz de confusión.

Cuadro 2: Reporte de clasificación del mejor modelo, la regresión logística.

Clase	Precisión	Sensibilidad	F1
No desastre	0.81	0.91	0.86
Desastre	0.85	0.72	0.78
Exactitud global	0.83		

El modelo reconoce con alta sensibilidad la clase de no desastre y es preciso al declarar un tweet como desastre, aunque deja pasar parte de los tweets de desastre reales, como se aprecia en la menor sensibilidad de esa clase.




Figura 5: Matriz de confusión del mejor modelo sobre el conjunto de prueba.

7. Función de clasificación de tweets

Se elaboró una función que recibe el texto de un tweet sin preprocesar, le aplica la misma limpieza y la misma representación de unigramas y bigramas utilizadas en el entrenamiento, y devuelve si el tweet se refiere a un desastre o no. Al probar la función con ejemplos redactados manualmente, clasificó correctamente como desastre mensajes sobre incendios forestales y terremotos, y como no desastre mensajes de contenido cotidiano, lo que confirma que la función integra de extremo a extremo el flujo de preprocesamiento, representación y predicción del mejor modelo.

8. Análisis de sentimiento

El sentimiento de cada tweet se calculó con VADER, un analizador basado en un léxico de valencias diseñado para el lenguaje de redes sociales, que interpreta emociones, mayúsculas y signos de exclamación. Por esta razón el sentimiento se calculó

sobre el texto original sin preprocesar, donde estos elementos aún están presentes, lo que responde de forma afirmativa a la pregunta de si vale la pena conservar los emoticones para esta etapa. Para cada tweet se contaron sus palabras positivas y negativas según el léxico y se obtuvo un puntaje compuesto que se tradujo en una etiqueta de sentimiento con los umbrales estándar. La distribución resultante fue de 3,707 tweets negativos, 2,013 neutros y 1,893 positivos, un predominio de la negatividad coherente con la temática del conjunto.

9. Tweets más positivos y más negativos por categoría

Se identificaron los diez tweets con el puntaje compuesto más bajo y los diez con el puntaje más alto, indicando la categoría de cada uno. Los más negativos concentran vocabulario de violencia y catástrofe y pertenecen mayoritariamente a la categoría de desastre, mientras que los más positivos corresponden a mensajes de tono celebratorio ubicados principalmente en la categoría de no desastre. El Cuadro 3 compara el sentimiento promedio entre categorías.

Cuadro 3: Sentimiento promedio por categoría.

Categoría	Negatividad	Positividad	Compuesto
No desastre	0.1323	0.1021	-0.0606
Desastre	0.1736	0.0493	-0.2646

Los tweets de desastre presentan una negatividad promedio mayor y un puntaje compuesto notablemente más bajo que los de no desastre, como se observa también en la Figura 6. Esto responde de forma afirmativa a la pregunta de si los tweets de desastre real son más negativos que los de la otra categoría y sugiere que una medida de negatividad podría aportar información al modelo.




Figura 6: Distribución del sentimiento compuesto por categoría.

10. Variable de negatividad

A partir del análisis anterior se creó una variable de negatividad, tomada del componente negativo de VADER, y se incorporó a la representación de texto para reentrenar el mejor modelo. El Cuadro 4 compara el desempeño del modelo entrenado solo con el texto frente al modelo que además incluye la variable, sobre el mismo conjunto de prueba.

Cuadro 4: Comparación del mejor modelo con y sin la variable de negatividad.

Representación	Exactitud	F1
Solo texto	0.8273	0.7821
Texto más negatividad	0.8234	0.7756

La inclusión de la variable de negatividad no mejoró la clasificación, la medida F1 disminuyó en 0.0065. La explicación es que la representación de texto ya captura gran parte de la señal de sentimiento a través de las propias palabras del tweet, de modo que una única variable agregada de negatividad resulta redundante y no aporta información nueva relevante para el modelo.

11. Conclusiones

Los tweets de desastre se pudieron clasificar con un buen desempeño a partir de una limpieza cuidadosa del texto y una representación de unigramas y bigramas ponderados por frecuencia inversa de documento. Entre los tres algoritmos comparados, la regresión logística obtuvo la mayor medida F1, con 0.78, y una exactitud de 0.83 sobre el conjunto de prueba. El análisis de frecuencias mostró un vocabulario de emergencia claramente distinto del cotidiano, y los n-gramas aportaron contexto que una sola palabra no captura.

El análisis de sentimiento con VADER, calculado sobre el texto original para aprovechar emoticones y puntuación, confirmó que los tweets de desastre son en promedio más negativos que el resto. Sin embargo, la variable de negatividad derivada de ese análisis no mejoró la clasificación, porque el texto ya contenía esa señal. La función de clasificación final recibe un tweet sin preprocesar, le aplica la misma limpieza y representación, y devuelve si el mensaje se refiere a un desastre real o no, cumpliendo el objetivo del laboratorio.